

上海财经大学

《大数据处理技术》课程实践报告

基于大规模 Steam 游戏数据的市场结构、玩家反馈与平台生态变化分析

姓名：张思拓

学号：2025134009

2026 年 5 月 20 日

摘要

在这里用 200–300 字概括报告内容。建议包括：数据来源、数据规模、使用的方法、核心分析方向、最重要的发现。请用你自己的话写核心观点。

关键词： 大数据处理；Steam 游戏；市场结构；玩家反馈；标签分析；可视化分析

目录

1	问题背景与研究目标	1
1.1	现实背景	1
1.2	研究问题	1
1.3	研究目标与技术路线	1
2	数据来源与字段说明	1
2.1	数据集来源	1
2.2	数据规模	2
2.3	字段类型	2
3	大规模表格数据处理方法	2
3.1	读取风险与处理策略	2
3.2	工具对比	2
3.3	最终处理方案	3
4	数据清洗与特征工程	3
4.1	数据质量检查	3
4.2	基础预处理	3
4.3	特征工程	3
5	Steam 游戏市场结构分析	4
5.1	发行年份趋势	4
5.2	价格结构与免费游戏比例	4
5.3	平台支持与开发者长尾	5
6	玩家反馈与热度分析	5
6.1	评论数量的长尾分布	5
6.2	好评率与评论数量门槛	5
6.3	推荐数、峰值在线与游玩时长	5
6.4	价格、平台与热度关系	5
7	标签、类型与市场定位分析	6
7.1	标签体系的基本结构	6

7.2	标签竞争度与反馈表现	6
7.3	标签共现与类型定位	7
7.4	独立游戏子市场	7
8	综合结论	7
8.1	对研究问题的回答	7
8.2	主要发现	7
8.3	管理或实践启示	7
9	不足与改进方向	7
9.1	当前不足	7
9.2	后续方向	7
10	AI 辅助与程序说明	8
10.1	AI 辅助说明	8
10.2	程序与环境说明	8
	参考资料	8

1 问题背景与研究目标

1.1 现实背景

说明为什么选择 Steam 游戏数据作为“大数据处理技术”课程项目。可以写：Steam 是重要的数字游戏发行平台，游戏数量多、字段复杂、玩家反馈丰富，适合做大规模表格数据分析。

1.2 研究问题

写清楚报告围绕哪些问题展开。建议保留两个核心问题：什么样的 Steam 游戏更容易获得玩家关注；Steam 游戏市场在 2024 到 2025 之间发生了什么变化。

1.3 研究目标与技术路线

说明你希望通过什么步骤回答问题。可以概括 Notebook 主线：数据理解、大表处理工具对比、数据清洗、特征工程、市场结构分析、玩家反馈分析、标签定位分析和报告综合。




图 1: Notebook 分析流程

2 数据来源与字段说明

2.1 数据集来源

介绍 Kaggle Steam Games Dataset 2025。写明原始数据来自 Kaggle，本地解压后位于 data/raw/archive/，由于文件较大不上传 GitHub。

2.2 数据规模

说明原始 CSV 总量约 1.7GB，包含 2024 和 2025 两个快照。可以列出主分析文件 games_march2025_cleaned.csv，以及快照对比文件 games_may2024_cleaned.csv。

表 1: 主要数据文件说明

文件名	约文件大小	约行数	用途
games_march2025_cleaned.csv	447MB	89,619	主分析文件
games_march2025_full.csv	450MB	94,949	2025 完整字段文件
games_may2024_cleaned.csv	403MB	83,647	快照对比文件
games_may2024_full.csv	405MB	87,807	2024 完整字段文件

2.3 字段类型

说明字段类型包括数值型、类别型、时间型、多标签型和文本型。这里可以结合课程中“表格数据分析”的字段类型识别思想。

3 大规模表格数据处理方法

3.1 读取风险与处理策略

说明为什么不能简单反复读取完整 CSV：文件大、字段多、文本列长、内存开销高。写明项目采用选择列读取、抽样检查、CSV 转 Parquet 等策略。

3.2 工具对比

总结 pandas、duckdb、polars 的角色。pandas 适合熟悉的数据分析与展示；duckdb 适合 SQL 式查询；polars 适合高性能 DataFrame 处理；pyarrow/Parquet 适合列式存储。




图 2: 不同工具处理时间对比

3.3 最终处理方案

写明最终策略：保留原始 CSV；清洗后生成可再生 Parquet；GitHub 不提交大型数据文件；提交 Notebook、图表和小型 summary CSV。

4 数据清洗与特征工程

4.1 数据质量检查

说明检查了缺失值、重复值、异常范围。特别说明 pct_pos_total 和 pct_pos_recent 中的 -1 是不可用值，不应该当作真实百分比。

4.2 基础预处理

说明 release_date 转换为日期，构造 release_year；数值字段转换；多标签字段解析；保留原始字段并新增辅助字段。

4.3 特征工程

列出主要特征：game_age_years、is_free、platform_count、review_count_calc、positive_rate_calc、genres_count、tags_count、description length、log 热度指标等。

5 Steam 游戏市场结构分析

5.1 发行年份趋势

根据 Notebook 04，用自己的话解释发行年份分布。可以写 2024 年是数据集中发行数量最高的年份，说明近年 Steam 游戏供给扩张明显。




图 3: Steam 游戏发行年份趋势

5.2 价格结构与免费游戏比例

说明免费游戏约占 15.80%，付费游戏仍占多数。可以讨论免费游戏降低进入门槛，但不能直接说明免费导致更高热度。




图 4: 免费游戏与付费游戏占比

5.3 平台支持与开发者长尾

说明 Windows 支持是基础结构，多平台游戏约占 23.05%。同时开发商和发行商分布具有长尾特征，说明 Steam 市场由头部主体和大量中小主体共同构成。

6 玩家反馈与热度分析

6.1 评论数量的长尾分布

写明评论数量高度长尾。当前数据中 72,563 款游戏至少有一条评论，33,358 款游戏达到 30 条及以上评论。评论数中位数为 13，均值约 1,479.70。




图 5: 玩家关注指标的 log 分布

6.2 好评率与评论数量门槛

说明好评率需要结合评论数理解。评论数很少时好评率不稳定，因此分析中使用 30 条评论作为较稳健门槛。

6.3 推荐数、峰值在线与游玩时长

说明推荐数、峰值在线和游玩时长都是热度或参与度指标，但含义不同。总结它们与评论数之间的相关关系，但注意不要写成因果关系。

6.4 价格、平台与热度关系

根据 Notebook 05 结果，讨论价格区间、免费/付费、多平台属性与热度指标的关系。强调这是描述性观察，不证明因果。

7 标签、类型与市场定位分析

7.1 标签体系的基本结构

说明数据中解析出 33 个类型、40 个分类和 452 个标签，平均每款游戏约 11.26 个标签。标签比类型更细，更适合描述市场定位。




图 6: 类型、分类与标签频次

7.2 标签竞争度与反馈表现

解释横轴“标签覆盖游戏数量”可以作为竞争度代理，纵轴好评率反映反馈倾向。可以讨论高频标签不一定好评更高，低竞争高反馈标签值得进一步关注。




图 7: 标签竞争度与好评率

7.3 标签共现与类型定位

说明标签经常组合出现，例如 Indie + Singleplayer 是较强共现组合之一。genre-tag 矩阵可以帮助理解粗类型和细标签之间的关系。

7.4 独立游戏子市场

说明 Indie 是最常见的市场定位之一，但 Indie 内部还可以继续拆分。Notebook 06 中 Short 在 Indie 定位游戏中相对更突出。

8 综合结论

8.1 对研究问题的回答

用你自己的话回答两个核心研究问题。建议分两段：第一段回答“哪些游戏更容易获得关注”；第二段回答“2024 到 2025 的变化”。这里是报告最核心部分，请尽量自己写。

8.2 主要发现

用 3-5 条总结最重要发现。建议覆盖：市场扩张、长尾结构、评论/热度长尾、标签定位价值、快照变化。

8.3 管理或实践启示

如果想让报告更像“分析报告”，可以写一点实践启示：例如开发者需要关注定位差异，不能只追逐高频标签；分析平台数据时要注意头部游戏对平均值的影响。

9 不足与改进方向

9.1 当前不足

说明数据来自第三方 Kaggle；分析以描述性为主；不能证明因果；快照口径可能变化；标签不完全等于真实内容；大型数据文件不提交但可再生成。

9.2 后续方向

说明后续可做 PCA、聚类、简单评分预测或相似游戏推荐系统。推荐系统可以使用 tags、genres、categories 和文本描述计算相似度，再用评论数、好评率、热度指标进行过滤或排序。

10 AI 辅助与程序说明

10.1 AI 辅助说明

说明本项目允许使用 AI Agent / Vibe Coding。你可以写：AI 主要用于代码生成、调试、LaTeX 环境配置和格式辅助；报告核心观点和最终解释由本人基于 Notebook 输出结果整理。

10.2 程序与环境说明

写明 Python 环境、主要依赖包、Notebook 文件名、LaTeX 编译方式。可以引用 README 和 requirements.txt。

表 2: 项目主要文件说明

文件或目录	说明
notebooks/01-07	数据分析主线 Notebook
data/raw/archive/	原始 Kaggle 数据，本地保存，不提交 GitHub
data/processed/	小型 summary CSV 和可再生中间数据
figures/	报告图表输出
reports/latex/main.tex	本报告 LaTeX 源文件
requirements.txt	Python 环境依赖

参考资料

- [1] Kaggle. Steam Games Dataset 2025.
<https://www.kaggle.com/datasets/artermiloff/steam-games-dataset>
- [2] Predicting the Popularity of Games on Steam. 项目参考论文，见 reports/references/。
- [3] Data-Driven Classifications of Video Game Vocabulary. 项目参考论文，见 reports/references/。
- [4] Enhancing Game Review Sentiment Classification on Steam Platform with Attention-Based BiLSTM. 项目参考论文，见 reports/references/。
- [5] Category-based and Popularity-guided Video Game Recommendation / CPGRec+. 项目参考论文，见 reports/references/。