

上海财经大学

《大数据处理技术》课程实践报告

基于大规模Steam游戏数据的市场结构、玩家反馈与平台
生态变化分析

姓名：张思拓

学号：2025134009

2026 年 5 月 20 日

摘要

在这里用 200–300 字概括报告内容。建议包括：数据来源、数据规模、使用的方法、核心分析方向、最重要的发现。请用你自己的话写核心观点。

关键词： 大数据处理；Steam 游戏；市场结构；玩家反馈；标签分析；可视化分析

目录

1	问题背景与研究目标	1
1.1	现实背景	1
1.2	研究问题	1
2	数据来源与字段说明	1
2.1	数据集来源	1
2.2	数据规模	2
2.3	字段类型	2
3	大规模表格数据处理方法	2
3.1	读取风险与处理策略	2
3.2	工具对比	3
4	数据清洗与特征工程	4
4.1	数据质量检查	4
4.2	基础预处理	4
4.3	特征工程	4
5	Steam游戏市场结构分析	4
5.1	发行年份趋势	4
5.2	价格结构与免费游戏比例	5
5.3	平台支持与开发者长尾	5
6	玩家反馈与热度分析	6
6.1	评论数量的长尾分布	6
6.2	好评率与评论数量门槛	6
6.3	推荐数、峰值在线与游玩时长	6
6.4	价格、平台与热度关系	6
7	标签、类型与市场定位分析	6
7.1	标签体系的基本结构	6
7.2	标签竞争度与反馈表现	7
7.3	标签共现与类型定位	7

7.4	独立游戏子市场	8
8	综合结论	8
8.1	对研究问题的回答	8
8.2	主要发现	8
8.3	管理或实践启示	8
9	不足与改进方向	8
9.1	当前不足	8
9.2	后续方向	8
	参考资料	8

1 问题背景与研究目标

1.1 现实背景

Steam是目前PC游戏领域中影响力较大的数字发行平台之一。平台上汇集了大量不同类型、不同规模和不同发行年代的游戏作品，既包括大型商业游戏，也包括独立游戏和中小团队作品。对于玩家来说，Steam不仅是购买和下载游戏的平台，也是查看游戏评价、浏览标签分类、了解游戏热度和参与社区互动的重要入口。

由于Steam长期积累了大量游戏信息和玩家反馈数据，其平台数据具有较强的分析价值。每款游戏通常包含发行时间、价格、支持平台、类型标签、开发商、发行商、玩家评论、推荐数、在线人数和游玩时长等字段。这些数据从不同角度记录了游戏的市场表现和玩家反馈，也为观察PC游戏市场的整体结构提供了较好的数据基础。

1.2 研究问题

基于Steam平台长期积累的游戏信息和玩家反馈数据，本次实践主要关注两个方面的问题。一方面，分析哪些Steam游戏更容易获得玩家关注。玩家关注度可以通过评论数量、推荐数、峰值在线人数和游玩时长等指标进行刻画，而价格、发行时间、平台支持情况、类型和标签等字段，则可以用于观察不同游戏特征与玩家关注度之间的关系。

另一方面，也关注Steam游戏市场在2024年5月到2025年3月之间的变化。通过对两个数据快照进行比较，可以观察这一阶段平台上的游戏数量、类型分布、标签结构、玩家反馈和热度表现是否出现变化。

2 数据来源与字段说明

2.1 数据集来源

本次实践使用的数据集为Kaggle平台上的[Steam Games Dataset 2025](#)。该数据集通过Steam商店页面爬取整理得到，并结合Steam API和Steam Spy等数据来源，收集了Steam平台上大量游戏的相关信息。

数据集更新至2025年3月，包含原始解析版本和清洗版本两类文件。其中，清洗版本去除了重复游戏和playtest版本，更适合用于后续的统计分析。数据内容涵盖游戏基本信息、发行时间、价格、平台支持情况、玩家评论、热度指标、类型和标签等字段，能够较好地反映Steam平台游戏数据的整体情况。

2.2 数据规模

该数据集由4个CSV文件组成，原始文件总大小约为1.7GB，包含2024年5月和2025年3月两个时间快照。每个时间快照都提供了full版本和cleaned版本，其中full版本保留的信息更完整，cleaned版本则去除了重复游戏和playtest版本，更适合进行统计分析。

2025年3月cleaned版本约447MB，包含约89,619行数据；2024年5月cleaned版本约403MB，包含约83,647行数据。两个时间快照的存在，使得数据不仅可以用于观察Steam平台在2025年3月时的整体情况，也可以用于比较2024年到2025年之间游戏数量和平台生态的变化。

表 1: 主要数据文件说明

文件名	约文件大小	约行数	用途
games_march2025_cleaned.csv	447MB	89,619	主分析文件
games_march2025_full.csv	450MB	94,949	2025 完整字段文件
games_may2024_cleaned.csv	403MB	83,647	快照对比文件
games_may2024_full.csv	405MB	87,807	2024 完整字段文件

2.3 字段类型

从字段结构来看，该数据集属于表格数据，其数据字段可以大致分为数值型、类别型、时间型、多标签型和文本型几类。其中，价格、评论数量、推荐数、峰值在线人数和游玩时长等字段属于数值型字段，可以用于统计和比较；平台支持情况、开发商、发行商等字段属于类别型字段，可以用于分组分析；发行日期属于时间型字段，可以用于观察游戏发行年份和市场变化趋势。

此外，数据集中还包含类型、分类和标签等多标签字段，这类字段往往不是单一取值，而是同时记录一款游戏的多个市场定位特征。游戏简介、详细描述等内容则属于文本型字段，能够补充说明游戏内容和主题。不同字段类型对应的分析方式并不相同，因此在后续处理前，需要先对字段结构进行识别和整理。

3 大规模表格数据处理方法

3.1 读取风险与处理策略

由于原始CSV文件体积较大，并且字段中包含较长的文本描述和多标签信息，如果每次分析都直接读取完整文件，会带来较高的读取时间和内存开销。尤其是在反

复调试代码和生成图表时，重复加载全部字段不仅效率较低，也容易让后续分析过程变得不稳定。

因此，在实际处理时，不会把完整的表格反复作为直接分析对象，而是先根据分析目标选择需要使用的核心字段。例如，在市场结构分析中主要关注发行时间、价格、平台、类型和标签字段；在玩家反馈分析中则重点读取评论数量、好评率、推荐数、峰值在线人数和游玩时长等字段。通过减少无关字段和长文本字段的重复读取，可以降低数据读取压力，也让后续分析更加集中。

同时，对于后续多次使用的核心数据，采用中间数据形式进行保存，避免每个分析步骤都从原始数据重新开始。这样既保留了原始数据的完整性，也提高了后续清洗、特征工程和可视化分析的效率。

3.2 工具对比

为了判断在这种大规模表格数据中，不同工具更适合承担什么任务，本次实践对pandas、duckdb和polars进行了简单对比。主要选取了三个与后续分析直接相关的任务作为评价维度：一是选列读取，即只读取后续分析需要的核心字段；二是年度聚合，即根据发行日期统计不同年份的游戏数量和相关指标；三是Parquet转换与读取，即观察列式中间文件是否能提高后续重复分析的效率。

从测试结果来看，pandas的优势在于使用直观，适合进行常规数据检查、结果整理和图表展示，但在直接读取CSV和聚合时速度相对较慢；duckdb适合进行SQL式查询和分组聚合，在年度汇总这类任务中表达较清晰，内存变化也相对较小；polars在选列读取、聚合和Parquet读写中整体速度较快，更适合承担大表读取和批量转换任务。Parquet文件在只保留核心字段后，文件体积明显小于原始CSV，也更适合后续反复读取。

因此，后续处理采用将核心字段转为Parquet，分析阶段按任务选择工具的方案。将需要多次使用的字段经过筛选和清洗后保存为可再生成的Parquet文件；pandas主要用于结果检查和可视化，duckdb用于部分汇总查询，polars用于较高性能的数据读取和格式转换。这样既保留了原始数据的完整性，也减少了后续反复读取完整数据带来的时间和内存开销。




图 1: 不同工具处理时间对比

4 数据清洗与特征工程

4.1 数据质量检查

说明检查了缺失值、重复值、异常范围。特别说明 pct_pos_total 和 pct_pos_recent 中的 -1 是不可用值，不应该当作真实百分比。

4.2 基础预处理

说明 release_date 转换为日期，构造 release_year；数值字段转换；多标签字段解析；保留原始字段并新增辅助字段。

4.3 特征工程

列出主要特征：game_age_years、is_free、platform_count、review_count_calc、positive_rate_calc、genres_count、tags_count、description length、log 热度指标等。

5 Steam游戏市场结构分析

5.1 发行年份趋势

根据 Notebook 04，用自己的话解释发行年份分布。可以写 2024 年是数据集中发行数量最高的年份，说明近年 Steam 游戏供给扩张明显。




图 2: Steam 游戏发行年份趋势

5.2 价格结构与免费游戏比例

说明免费游戏约占 15.80%，付费游戏仍占多数。可以讨论免费游戏降低进入门槛，但不能直接说明免费导致更高热度。




图 3: 免费游戏与付费游戏占比

5.3 平台支持与开发者长尾

说明 Windows 支持是基础结构，多平台游戏约占 23.05%。同时开发商和发行商分布具有长尾特征，说明 Steam 市场由头部主体和大量中小主体共同构成。

6 玩家反馈与热度分析

6.1 评论数量的长尾分布

写明评论数量高度长尾。当前数据中 72,563 款游戏至少有一条评论，33,358 款游戏达到 30 条及以上评论。评论数中位数为 13，均值约 1,479.70。




图 4: 玩家关注指标的 log 分布

6.2 好评率与评论数量门槛

说明好评率需要结合评论数理解。评论数很少时好评率不稳定，因此分析中使用 30 条评论作为较稳健门槛。

6.3 推荐数、峰值在线与游玩时长

说明推荐数、峰值在线和游玩时长都是热度或参与度指标，但含义不同。总结它们与评论数之间的相关关系，但注意不要写成果因果关系。

6.4 价格、平台与热度关系

根据 Notebook 05 结果，讨论价格区间、免费/付费、多平台属性与热度指标的关系。强调这是描述性观察，不证明因果。

7 标签、类型与市场定位分析

7.1 标签体系的基本结构

说明数据中解析出 33 个类型、40 个分类和 452 个标签，平均每款游戏约 11.26 个标签。标签比类型更细，更适合描述市场定位。




图 5: 类型、分类与标签频次

7.2 标签竞争度与反馈表现

解释横轴“标签覆盖游戏数量”可以作为竞争度代理，纵轴好评率反映反馈倾向。可以讨论高频标签不一定好评更高，低竞争高反馈标签值得进一步关注。




图 6: 标签竞争度与好评率

7.3 标签共现与类型定位

说明标签经常组合出现，例如 Indie + Singleplayer 是较强共现组合之一。genre-tag 矩阵可以帮助理解粗类型和细标签之间的关系。

7.4 独立游戏子市场

说明 Indie 是最常见的市场定位之一，但 Indie 内部还可以继续拆分。Notebook 06 中 Short 在 Indie 定位游戏中相对更突出。

8 综合结论

8.1 对研究问题的回答

用你自己的话回答两个核心研究问题。建议分两段：第一段回答“哪些游戏更容易获得关注”；第二段回答“2024 到 2025 的变化”。这里是报告最核心部分，请尽量自己写。

8.2 主要发现

用 3-5 条总结最重要发现。建议覆盖：市场扩张、长尾结构、评论/热度长尾、标签定位价值、快照变化。

8.3 管理或实践启示

如果想让报告更像“分析报告”，可以写一点实践启示：例如开发者需要关注定位差异，不能只追逐高频标签；分析平台数据时要注意头部游戏对平均值的影响。

9 不足与改进方向

9.1 当前不足

说明数据来自第三方 Kaggle；分析以描述性为主；不能证明因果；快照口径可能变化；标签不完全等于真实内容；大型数据文件不提交但可再生成。

9.2 后续方向

说明后续可做 PCA、聚类、简单评分预测或相似游戏推荐系统。推荐系统可以使用 tags、genres、categories 和文本描述计算相似度，再用评论数、好评率、热度指标进行过滤或排序。

参考资料

[1] Kaggle. Steam Games Dataset 2025.

<https://www.kaggle.com/datasets/artermiloff/steam-games-dataset>

- [2] Predicting the Popularity of Games on Steam. 项目参考论文, 见 reports/references/。
- [3] Data-Driven Classifications of Video Game Vocabulary. 项目参考论文, 见 reports/references/。
- [4] Enhancing Game Review Sentiment Classification on Steam Platform with Attention-Based BiLSTM. 项目参考论文, 见 reports/references/。
- [5] Category-based and Popularity-guided Video Game Recommendation / CPGRec+. 项目参考论文, 见 reports/references/。