

上海财经大学

《大数据处理技术》课程实践报告

基于大规模Steam游戏数据的市场结构、玩家反馈与平台
生态变化分析

姓名：张思拓

学号：2025134009

2026 年 5 月 21 日

摘要

本文以Steam平台游戏数据为研究对象，围绕游戏市场结构、玩家反馈和平台生态变化进行分析。研究首先对原始数据进行整理和质量检查，在此基础上构造适合分析的辅助特征，并通过可视化方法观察游戏发行趋势、价格结构、平台支持、类型标签、玩家评论和热度指标之间的关系。分析结果显示，Steam游戏供给在近年持续扩张，市场中既存在少数高热度作品，也存在大量长尾游戏；评论数量、推荐数和在线人数等指标能够反映玩家关注度，但不能直接等同于游戏口碑。类型和标签方面，高频标签并不必然对应更好的玩家反馈，细分标签和标签组合更能体现游戏的市场定位。进一步从发行策略角度看，买断制游戏、免费在线游戏和高投入游戏所关注的指标并不相同：买断制游戏更需要结合估计销量和价格区间理解商业表现，免费游戏更依赖评论反馈和持续参与，高投入游戏则需要同时关注讨论热度和口碑表现。整体来看，Steam游戏市场具有明显的多层次结构，单一指标难以完整解释游戏表现，综合分析价格、反馈、热度和市场定位有助于更好地理解平台生态。

项目仓库： [TobyKSKGD/Ultimate_Game_Insights](#)

关键词： 大数据处理；Steam游戏；市场结构；玩家反馈；标签分析；可视化分析

目录

1	问题背景与研究目标	1
1.1	现实背景	1
1.2	研究问题	1
2	数据来源与字段说明	1
2.1	数据集来源	1
2.2	数据规模	2
2.3	字段类型	2
3	大规模表格数据处理方法	2
3.1	读取风险与处理策略	2
3.2	工具对比	3
4	数据清洗与特征工程	4
4.1	数据质量检查	4
4.2	基础预处理	4
4.3	特征工程	5
5	Steam游戏市场结构分析	5
5.1	发行年份趋势	5
5.2	价格结构与免费游戏比例	6
5.3	平台支持与开发者长尾	6
6	玩家反馈与热度分析	7
6.1	评论数量的长尾分布	7
6.2	好评率与评论数量门槛	8
6.3	推荐数、峰值在线与游玩时长	8
6.4	价格、平台与热度关系	9
7	标签、类型与市场定位分析	9
7.1	标签体系的基本结构	9
7.2	标签竞争度与反馈表现	10
7.3	标签共现与类型定位	11

7.4 独立游戏子市场	11
8 综合结论	12
8.1 主要发现	12
8.2 额外发现	13
8.3 实践启示	13
9 不足与改进方向	16
9.1 当前不足	16
9.2 后续方向	16
参考资料	17

1 问题背景与研究目标

1.1 现实背景

Steam是目前PC游戏领域中影响力较大的数字发行平台之一。平台上汇集了大量不同类型、不同规模和不同发行年代的游戏作品，既包括大型商业游戏，也包括独立游戏和中小团队作品。对于玩家来说，Steam不仅是购买和下载游戏的平台，也是查看游戏评价、浏览标签分类、了解游戏热度和参与社区互动的重要入口。

由于Steam长期积累了大量游戏信息和玩家反馈数据，其平台数据具有较强的分析价值。每款游戏通常包含发行时间、价格、支持平台、类型标签、开发商、发行商、玩家评论、推荐数、在线人数和游玩时长等字段。这些数据从不同角度记录了游戏的市场表现和玩家反馈，也为观察PC游戏市场的整体结构提供了较好的数据基础。

1.2 研究问题

基于Steam平台长期积累的游戏信息和玩家反馈数据，本次实践主要关注两个方面的问题。一方面，分析哪些Steam游戏更容易获得玩家关注。玩家关注度可以通过评论数量、推荐数、峰值在线人数和游玩时长等指标进行刻画，而价格、发行时间、平台支持情况、类型和标签等字段，则可以用于观察不同游戏特征与玩家关注度之间的关系。

另一方面，也关注Steam游戏市场在2024年5月到2025年3月之间的变化。通过对两个数据快照进行比较，可以观察这一阶段平台上的游戏数量、类型分布、标签结构、玩家反馈和热度表现是否出现变化。

2 数据来源与字段说明

2.1 数据集来源

本次实践使用的数据集为Kaggle平台上的[Steam Games Dataset 2025](#)。该数据集通过Steam商店页面爬取整理得到，并结合Steam API和Steam Spy等数据来源，收集了Steam平台上大量游戏的相关信息。

数据集更新至2025年3月，包含原始解析版本和清洗版本两类文件。其中，清洗版本去除了重复游戏和playtest版本，更适合用于后续的统计分析。数据内容涵盖游戏基本信息、发行时间、价格、平台支持情况、玩家评论、热度指标、类型和标签等字段，能够较好地反映Steam平台游戏数据的整体情况。

2.2 数据规模

该数据集由4个CSV文件组成，原始文件总大小约为1.7GB，包含2024年5月和2025年3月两个时间快照。每个时间快照都提供了full版本和cleaned版本，其中full版本保留的信息更完整，cleaned版本则去除了重复游戏和playtest版本，更适合进行统计分析。

2025年3月cleaned版本约447MB，包含约89,619行数据；2024年5月cleaned版本约403MB，包含约83,647行数据。两个时间快照的存在，使得数据不仅可以用于观察Steam平台在2025年3月时的整体情况，也可以用于比较2024年到2025年之间游戏数量和平台生态的变化。

表 1: 主要数据文件说明

文件名	约文件大小	约行数	用途
games_march2025_cleaned.csv	447MB	89,619	主分析文件
games_march2025_full.csv	450MB	94,949	2025 完整字段文件
games_may2024_cleaned.csv	403MB	83,647	快照对比文件
games_may2024_full.csv	405MB	87,807	2024 完整字段文件

2.3 字段类型

从字段结构来看，该数据集属于表格数据，其数据字段可以大致分为数值型、类别型、时间型、多标签型和文本型几类。其中，价格、评论数量、推荐数、峰值在线人数和游玩时长等字段属于数值型字段，可以用于统计和比较；平台支持情况、开发商、发行商等字段属于类别型字段，可以用于分组分析；发行日期属于时间型字段，可以用于观察游戏发行年份和市场变化趋势。

此外，数据集中还包含类型、分类和标签等多标签字段，这类字段往往不是单一取值，而是同时记录一款游戏的多个市场定位特征。游戏简介、详细描述等内容则属于文本型字段，能够补充说明游戏内容和主题。不同字段类型对应的分析方式并不相同，因此在后续处理前，需要先对字段结构进行识别和整理。

3 大规模表格数据处理方法

3.1 读取风险与处理策略

由于原始CSV文件体积较大，并且字段中包含较长的文本描述和多标签信息，如果每次分析都直接读取完整文件，会带来较高的读取时间和内存开销。尤其是在反

复调试代码和生成图表时，重复加载全部字段不仅效率较低，也容易让后续分析过程变得不稳定。

因此，在实际处理时，不会把完整的表格反复作为直接分析对象，而是先根据分析目标选择需要使用的核心字段。例如，在市场结构分析中主要关注发行时间、价格、平台、类型和标签字段；在玩家反馈分析中则重点读取评论数量、好评率、推荐数、峰值在线人数和游玩时长等字段。通过减少无关字段和长文本字段的重复读取，可以降低数据读取压力，也让后续分析更加集中。

同时，对于后续多次使用的核心数据，采用中间数据形式进行保存，避免每个分析步骤都从原始数据重新开始。这样既保留了原始数据的完整性，也提高了后续清洗、特征工程和可视化分析的效率。

3.2 工具对比

为了判断在这种大规模表格数据中，不同工具更适合承担什么任务，本次实践对pandas、duckdb和polars进行了简单对比。主要选取了三个与后续分析直接相关的任务作为评价维度：一是选列读取，即只读取后续分析需要的核心字段；二是年度聚合，即根据发行日期统计不同年份的游戏数量和相关指标；三是Parquet转换与读取，即观察列式中间文件是否能提高后续重复分析的效率。

从测试结果来看，pandas的优势在于使用直观，适合进行常规数据检查、结果整理和图表展示，但在直接读取CSV和聚合时速度相对较慢；duckdb适合进行SQL式查询和分组聚合，在年度汇总这类任务中表达较清晰，内存变化也相对较小；polars在选列读取、聚合和Parquet读写中整体速度较快，更适合承担大表读取和批量转换任务。Parquet文件在只保留核心字段后，文件体积明显小于原始CSV，也更适合后续反复读取。

因此，后续处理采用将核心字段转为Parquet，分析阶段按任务选择工具的方案。将需要多次使用的字段经过筛选和清洗后保存为可再生成的Parquet文件；pandas主要用于结果检查和可视化，duckdb用于部分汇总查询，polars用于较高性能的数据读取和格式转换。这样既保留了原始数据的完整性，也减少了后续反复读取完整数据带来的时间和内存开销。




图 1: 不同工具处理时间对比

4 数据清洗与特征工程

4.1 数据质量检查

在正式分析前，先对数据进行了基础质量检查，主要包括字段缺失情况、重复记录和数值范围三个方面。由于Steam游戏以appid作为主要标识，因此重点检查了appid是否缺失或重复，避免同一款游戏在后续统计中被重复计算。同时，也对价格、评论数量、推荐数、峰值在线人数、发行年份等字段进行了范围检查，以识别明显不合理的取值。

检查过程中还发现，pct_pos_total和pct_pos_recent这两个好评率相关字段中存在-1取值。这里的-1并不表示真实的百分比，而是表示该字段没有可用统计结果。因此，在后续处理时将这类取值视为缺失值，避免其影响好评率分析。

4.2 基础预处理

在完成数据质量检查后，进一步对字段进行了基础预处理。首先，将release_date字段转换为日期格式，并在此基础上提取release_year，用于后续按发行年份分析Steam游戏数量变化。同时，对价格、评论数量、推荐数、峰值在线人数、游玩时长等数值字段进行了统一转换，减少因字段类型不一致带来的统计问题。

对于genres、categories、tags、developers和publishers等多标签字段，则将原本混合在同一单元格中的多个取值进行解析，并进一步构造对应的数量特征。整个预处理过程中尽量保留原始字段，同时新增release_year、game_age_years、platform_count、review_count_calc、positive_rate_calc以及各类标签数量等辅助字段，为后续市场结构、玩家反馈和标签定位分析提供统一的数据基础。

4.3 特征工程

为了方便后续的分析，进一步构造若干辅助分析特征。首先，根据发行日期生成game_age_years，用于表示游戏距当前快照时间的大致年限；根据价格字段生成is_free，用于区分免费游戏和买断制游戏；根据windows、mac和linux三个平台字段生成platform_count，用于衡量游戏的平台支持数量。

在玩家反馈方面，使用positive和negative重新计算review_count_calc和positive_rate_calc，以减少直接依赖原始百分比字段带来的影响。对于类型和标签字段，则构造genres_count、categories_count和tags_count，用于描述一款游戏的市场定位复杂度。同时，还根据游戏简介和详细描述生成文本长度特征，并对评论数、推荐数、峰值在线人数等长尾分布明显的热度指标进行log转换，便于后续比较和可视化分析。

5 Steam游戏市场结构分析

5.1 发行年份趋势

Steam平台的游戏供给主要集中在近十多年，尤其是2020年以后增长更加明显。在当前主分析数据中，发行年份有效范围为1997年到2025年，其中2020年代游戏数量达到60610款，已经明显超过2010年代的28907款。这说明Steam平台上的游戏供给在近几年快速扩张，平台内容规模持续增加。

具体到年度变化，2014年以后游戏发行数量开始明显上升，2020年后基本保持在较高水平。2023年发行游戏数量为12735款，2024年进一步上升到18282款，是当前数据集中发行数量最高的年份。2025年由于数据快照截止到3月，因此不能直接与完整年份比较。整体来看，Steam游戏市场呈现出明显的供给扩张趋势，玩家可选择的游戏数量持续增加，但这也意味着单款游戏面临的竞争压力可能同步加大。




图 2: Steam 游戏发行年份趋势

5.2 价格结构与免费游戏比例

从价格结构来看，Steam平台仍然以买断制游戏为主。在当前数据中，买断制游戏共有75458款，占比约84.20%；免费游戏共有14160款，占比约15.80%。这说明免费游戏虽然已经是平台中比较重要的一部分，但从游戏数量上看，买断制模式仍然是Steam游戏市场的主体。

在买断制游戏内部，价格分布也呈现出明显的集中和长尾特征。买断制游戏的价格中位数为4.99，说明大量游戏集中在较低价格区间；同时，少数游戏价格明显偏高，最高价格甚至达到数百以上。整体来看，Steam平台并不是单一价格层级的市场，而是同时包含免费游戏、低价游戏、常规定价游戏和少量高价产品。

从玩家反馈角度看，免费游戏的平均评论数高于买断制游戏，但中位评论数反而低于买断制游戏。这说明免费游戏更容易出现少数特别热门的头部分品，从而拉高平均值；但对于一般游戏而言，免费并不必然意味着更高的玩家关注度。因此，不能简单得出“免费游戏更受欢迎”的结论，而需要结合评论数分布、推荐数和在线人数等指标综合判断。




图 3: 免费游戏与买断制游戏占比

5.3 平台支持与开发者长尾

从平台支持结构来看，Windows仍然是Steam游戏最主要的运行平台。在当前数据中，支持Windows的游戏共有89588款，几乎覆盖全部样本；支持Mac的游戏为17438款，占比约19%；支持Linux的游戏为12627款，占比约14%。从平台组合来看，仅支持Windows的游戏占比约77%，而同时支持多个平台的游戏占比约23.05%。这说明Steam虽然具有跨平台特征，但从游戏供给角度看，Windows仍然是绝对核心的平

台基础。

进一步比较平台数量可以发现，支持平台越多的游戏，其中位评论数相对更高。仅支持1个平台的游戏的中位评论数为11，支持2个平台的游戏为21，支持3个平台的游戏为40。这可能说明多平台游戏往往具有更广的潜在玩家覆盖面，也可能与游戏本身的开发投入、发行策略有关。不过，这种结果只能说明平台支持数量与玩家关注度之间存在一定相关现象，不能直接说明多平台支持本身导致游戏更受欢迎。

开发商和发行商分布则体现出明显的长尾结构。数据中解析出的开发商数量超过6万个，发行商数量接近5万个，并且二者的中位作品数都为1。这说明Steam平台上存在大量只发布少数游戏的开发者和发行主体。与此同时，头部开发商和发行商虽然作品数量更多，但集中度并不算高，前100名开发商覆盖约6.87%的开发商作品记录，前100名发行商覆盖约11.44%的发行商作品记录。整体来看，Steam市场并不是由少数头部主体完全主导，而是由少数高产主体和大量中小开发者共同构成。

6 玩家反馈与热度分析

6.1 评论数量的长尾分布

从玩家反馈规模来看，Steam游戏的评论数量呈现出非常明显的长尾分布。当前数据中共有89618款游戏，其中72563款至少有1条评论，33358款评论数达到30条及以上。也就是说，大部分游戏虽然能够获得一定玩家反馈，但真正拥有较稳定评论规模的游戏只占其中一部分。

从统计结果看，评论数的中位数只有13，而均值约为1479.70，二者差距很大。这说明评论数量并不是均匀分布的，而是被少数头部游戏明显拉高。大量游戏的评论数处于较低水平，少数热门游戏则积累了极高的评论数量。类似的长尾现象也出现在推荐数和峰值在线人数中，说明玩家关注度在Steam平台上高度集中。

因此，不能只依赖平均值来判断游戏的整体表现。对于这类长尾数据，中位数、分位数和log变换后的分布更能反映大多数游戏的真实情况。同时，评论数量更多代表玩家参与反馈的规模，并不直接等同于游戏质量，还需要结合好评率等指标进一步分析。




图 4: 玩家关注指标的 log 分布

6.2 好评率与评论数量门槛

好评率可以反映玩家反馈的倾向，但它需要和评论数量一起理解。如果一款游戏只有很少评论，即使好评率达到100%，也不能说明它已经获得了稳定的玩家认可；相反，评论数量较多的游戏，其好评率更能代表较大玩家群体的整体反馈。因此，在分析好评率时，不能只看百分比本身，还需要设置一定的评论数量门槛。

在当前数据中，评论数量达到30条及以上的游戏共有33358款。以这部分游戏作为相对稳定的样本后，好评率分布更加具有参考意义。其中，评论数达到门槛的游戏好评率中位数约为81.08%，说明多数获得一定评论规模的Steam游戏整体反馈偏正向。不过，不同游戏之间仍然存在明显差异，一些游戏虽然评论数量较多，但好评率并不高；也有部分游戏评论规模不算特别大，却保持了较好的玩家评价。

因此，后续分析中将30条评论作为观察好评率的基本门槛，不是为了排除小体量游戏，而是为了减少极少量评论带来的偶然性，使好评率更适合用于比较不同游戏类型、标签和市场定位下的玩家反馈表现。

6.3 推荐数、峰值在线与游玩时长

推荐数、峰值在线人数和游玩时长都可以作为玩家热度的补充指标，但三者反映的含义并不完全相同。推荐数更接近平台内部的累计关注信号，峰值在线人数更能体现某一阶段的活跃程度，游玩时长则反映玩家在游戏中投入的时间。当前数据中，推荐数、峰值在线人数和平均游玩时长的中位数均为0，说明大量游戏在这些指标上没有形成明显积累，热度仍然集中在少数头部作品中。

从分位数结果看，这种差异非常明显。推荐数在75%分位数时仍为0，但到90%分位数已经达到357，99%分位数则达到13735以上；峰值在线人数在90%分位数只有3，但99%分位数上升到约446。这说明多数游戏的可见热度较低，而少数游戏能够获得远高于普通作品的玩家规模。

不同热度指标之间也存在一定相关性。评论数与推荐数的相关性较强，推荐数

与峰值在线人数之间也呈现较明显的正相关，说明这些指标都在一定程度上反映了“玩家关注度”。但它们不能完全等同：评论数偏向累计反馈，峰值在线偏向实时活跃，游玩时长则受到游戏类型和玩法机制影响。

6.4 价格、平台与热度关系

从价格区间来看，游戏价格与玩家热度之间并不是简单的线性关系。免费游戏数量较多，但其中位评论数为0，说明大量免费游戏并没有获得稳定反馈；同时，免费游戏的平均评论数较高，主要是因为少数头部免费游戏积累了大量玩家反馈。买断制游戏中，评论数中位数随着价格区间上升整体有所提高，其中20到40美元区间的中位评论数达到263.5，高于其他价格段。这说明较高价格游戏往往具有更强的市场可见度或更高的玩家投入，但这并不代表价格本身直接带来热度。

好评率方面，达到30条评论门槛后的游戏中，5到20美元区间的中位好评率相对较高，10到20美元区间约为83.50%。相比之下，免费游戏的中位好评率约为77.45%，40美元以上区间约为79.73%。这说明较低价格并不一定对应更高评价，高价游戏也不一定天然更受认可。价格更像是游戏规模、商业模式和目标玩家群体的综合体现，不能单独作为判断游戏表现的依据。

从平台支持数量来看，支持平台越多的游戏，中位评论数和好评率整体更高。仅支持1个平台的游戏的中位评论数为11，支持2个平台的游戏为21，支持3个平台的游戏为40；对应的好评率中位数也从约79.63%上升到84%左右。这可能说明多平台游戏拥有更广的潜在玩家覆盖面，也可能反映出这类游戏通常具备更高的开发投入和发行成熟度。因此，价格和平台支持都可以作为理解热度差异的辅助变量，但仍应被视为描述性观察，不能直接解释为因果关系。

7 标签、类型与市场定位分析

7.1 标签体系的基本结构

从标签体系来看，Steam数据中的genres、categories和tags分别对应不同层次的游戏描述。genres更接近传统意义上的游戏类型，categories更多记录游戏功能和平台特性，而tags则更加细致，既包括玩法、题材，也包括画面风格和玩家体验等信息。

当前数据中共解析出33个类型、40个分类和452个标签。其中，平均每款游戏约有2.88个类型、4.20个分类和11.26个标签，说明tags的覆盖粒度明显更细。具体来看，最常见的类型是Indie，覆盖63189款游戏；最常见的分类是Single-player，覆盖84399款游戏；最常见的标签同样是Indie，覆盖43408款游戏。这说明独立游戏和单人游玩仍然是Steam平台中非常突出的内容结构。

相比genres和categories，tags更适合用于分析市场定位。因为一款游戏通常不会只属于一个简单类型，而是会同时具有多个标签组合，例如玩法、视角、题材和情绪体验等。也正因为如此，后续分析不只关注标签出现次数，而是进一步观察标签的竞争程度、反馈表现和共现关系，从而理解不同游戏在Steam市场中的定位差异。



图 5: 类型、分类与标签频次

7.2 标签竞争度与反馈表现

为了进一步观察不同标签的市场表现，可以将“标签覆盖游戏数量”作为竞争度的近似指标。覆盖游戏数量越多，说明使用该标签的游戏越多，玩家在该标签下能够看到的同类作品也越多；而好评率则可以反映该标签下游戏整体反馈的大致倾向。

从结果来看，高频标签并不一定对应更高的好评率。例如Indie、Singleplayer、Adventure等标签覆盖游戏数量很大，说明它们是Steam平台中非常常见的定位方式，但由于样本范围较广，内部游戏质量和玩家反馈差异也更大。因此，高频标签更多反映市场规模和竞争程度，并不能直接说明该类游戏更容易获得好评。

相对而言，一些覆盖数量较少但好评率较高的标签更值得关注。这类标签通常代表更细分的玩法或题材方向，竞争压力相对较低，同时能够吸引较明确的目标玩家群体。比如在筛选结果中，Sokoban等标签表现出低竞争、高反馈的特征，说明细分标签可能比宽泛标签更能体现游戏的差异化定位。整体来看，标签分析的价值不只在于找出最热门的标签，更在于识别哪些细分方向能够在相对有限的竞争中获得较好的玩家反馈。




图 6: 标签竞争度与好评率

7.3 标签共现与类型定位

从标签关系来看，Steam游戏的市场定位通常不是由单个标签决定的，而是由多个标签组合共同形成。许多高频标签会反复共同出现，例如Indie+Singleplayer就是较强的共现组合之一。这说明大量Steam游戏会同时使用“独立游戏”和“单人游戏”来描述自身定位，也反映出平台中独立、单人向作品的数量较多。

标签共现关系可以帮助理解玩家在浏览游戏时看到的定位组合。单独看Indie、Adventure或Action这类标签，只能知道某一类游戏数量较多；但观察标签共现后，可以进一步看到这些标签经常和哪些玩法、题材或体验标签搭配出现。也就是说，标签共现不只是统计“哪些标签最多”，而是揭示游戏在平台中如何被组合式地描述。

同时，genre-tag矩阵也展示了粗类型和细标签之间的关系。genres提供的是较概括的类型划分，而tags则提供更细的市场定位信息。例如同样属于Action或Adventure的游戏，在tags层面可能进一步分化为Singleplayer、Open World、Puzzle、RPG等不同方向。因此，结合类型和标签进行分析，可以比单独查看类型分布更细致地理解Steam游戏市场的内部结构。

7.4 独立游戏子市场

Indie是Steam平台中最常见的市场定位之一，在类型和标签统计中都处于非常靠前的位置。这说明独立游戏已经不是一个很小的边缘类别，而是Steam游戏供给中的重要组成部分。不过，Indie本身是一个较宽泛的标签，只能说明游戏的开发和市

场定位特征，并不能直接反映具体玩法、题材和玩家体验。

因此，还需要进一步观察Indie标签内部的细分结构。从结果来看，Indie游戏中仍然会和Singleplayer、Adventure、Casual、Puzzle等标签共同出现，说明独立游戏内部也包含多种不同方向。其中，Short在Indie定位游戏中相对更突出，说明短流程、小体量或轻量化体验是独立游戏中比较有代表性的细分特征之一。

这也说明，在分析Steam游戏市场时，不能只停留在“独立游戏数量多”这一层结论上。Indie更像是一个入口标签，真正决定市场差异的往往是它与其他标签的组合关系。对于中小开发者而言，单纯使用Indie标签并不能形成足够明确的差异化定位，进一步突出具体玩法、体验长度或题材特征，可能更有助于让游戏在同类作品中被玩家识别。

8 综合结论

8.1 主要发现

针对最开始提出的第一个问题，从分析结果来看，更容易获得玩家关注的Steam游戏通常不是由单一因素决定的，而是受到价格、发行时间、平台支持、类型标签和玩家反馈规模等多方面影响。评论数量、推荐数和峰值在线人数之间存在一定相关性，说明它们都能在不同角度上反映游戏的热度。但这些指标也都呈现出明显的长尾分布，大量游戏的评论数、推荐数和在线人数较低，少数头部游戏则积累了远高于普通游戏的关注度。因此，Steam平台上的玩家关注并不是平均分布的，而是明显集中在少数高热度作品中。

从具体特征来看，免费游戏虽然平均评论数较高，但中位评论数并不突出，说明免费模式更容易产生少数头部爆款，但并不代表所有免费游戏都能获得更高关注。买断制游戏中，中高价格区间的评论数中位数相对更高，可能与游戏体量、制作投入和发行策略有关。平台支持方面，支持平台数量更多的游戏通常具有更高的中位评论数和好评率，这可能说明多平台游戏具有更广的潜在玩家覆盖面，也可能反映其整体开发和发行成熟度更高。类型和标签方面，Indie、Singleplayer、Action、Adventure等标签覆盖范围较广，但高频标签并不必然带来更高好评率。相比之下，一些更细分、竞争度较低且反馈较好的标签，可能更能体现游戏的差异化定位。

针对第二个问题，从2024年5月到2025年3月两个数据快照来看，Steam游戏市场在数据集中继续呈现扩张趋势。2024年5月清洗版本中包含83646个唯一appid，而2025年3月清洗版本中增加到89618个唯一appid，说明平台游戏供给数量仍在增长。发行年份分布也显示，2020年以后Steam游戏数量维持在较高水平，2024年是当前数据中发行数量最高的年份，达到18282款。这反映出Steam平台的内容供给仍然活跃，

玩家面对的游戏选择也在继续增加。

玩家反馈规模也在两个快照之间有所扩大。总评论数从2024年5月的124126364条增加到2025年3月的132607623条，推荐数也有所上升，说明平台上的玩家反馈和互动规模仍在积累。不过，评论数、推荐数和峰值在线人数仍然保持明显的长尾结构，说明新增游戏数量和反馈规模的增长，并不意味着所有游戏都能平均获得关注。整体来看，2024年到2025年间，Steam市场表现出游戏供给继续扩张、反馈规模继续增加、头部集中和长尾竞争并存的特点。由于两个快照可能受到采集时间和数据清洗口径影响，因此这些变化更适合被理解为数据集中观察到的市场变化，而不是对整个平台作绝对化判断。

8.2 额外发现

除前文两个主要研究问题外，数据分析过程中还得到了一些额外观察。

第一，Steam平台的游戏供给具有明显的长尾特征。不仅评论数、推荐数和峰值在线人数呈现长尾分布，开发商和发行商分布也具有类似特征。大量开发者只发布了少数作品，而少数头部主体拥有更多游戏数量。这说明Steam平台并不是单纯由头部厂商构成，而是同时容纳了大量中小团队和独立开发者。

第二，免费游戏并不必然意味着更高关注度。虽然免费游戏的平均评论数较高，但这主要受到少数头部免费游戏影响。从中位数来看，大量免费游戏并没有形成稳定的玩家反馈。因此，免费模式更像是一种降低进入门槛的发行方式，而不是获得玩家关注的充分条件。

第三，标签比传统类型更能反映游戏的市场定位。genres能够提供较粗的类型划分，但tags包含了玩法、题材、风格和体验等更细的信息。尤其是在Indie这类宽泛标签内部，不同游戏之间仍然存在明显差异。通过标签共现和标签反馈分析，可以更细致地观察游戏在Steam市场中的定位方式。

第四，玩家关注度和玩家评价需要分开理解。评论数、推荐数和峰值在线人数更多反映游戏是否被看见、是否被讨论，而好评率则反映玩家反馈倾向。一款游戏热度高并不一定代表评价更好，低热度游戏也可能在特定细分标签下获得较高好评。因此，在分析Steam游戏表现时，不能只用单一指标判断游戏“好不好”或“火不火”。

8.3 实践启示

在前面的分析中，评论数、推荐数和峰值在线人数主要反映游戏的讨论热度和玩家参与度。但对于Steam游戏发行来说，讨论热度并不一定等同于商业表现。尤其是买断制游戏，玩家购买后即使没有长期游玩或发表评论，也已经形成了一定的基础收入。因此，在本节中进一步将estimated_owners作为估计销量规模的代理指标，

用来补充前面对热度和反馈的分析。需要说明的是，该字段并不是Steam官方销量，只能反映大致拥有者区间，因此更适合作为趋势观察，而不能作为精确的商业预测。

对于买断制游戏，价格并不是越低越容易取得更好的结果。数据显示，0.01到4.99美元区间的买断制游戏数量最多，共39388款，但估计拥有者中位数仅为10000，粗略收入代理中位数只有29900。相比之下，10到19.99美元区间和20到39.99美元区间虽然游戏数量更少，但粗略收入代理中位数分别达到189900和399900，评论数中位数也更高。40到79.99美元区间的估计拥有者中位数达到35000，粗略收入代理中位数超过200万，但这一区间通常对应更高制作体量和更强发行能力，并不一定适合普通独立开发者直接模仿。图7可以更直观地看到，极低价格区间并没有在估计拥有者中位数上形成明显优势，而较高价格区间的粗略收入代理明显更高。因此，对于资源有限的独立开发者来说，极低价并不一定是最优选择，更可行的策略是在玩家可接受的中低价格区间内，提供足够明确的内容体量和差异化卖点。




图 7: 买断制游戏不同价格区间的估计拥有者与粗略收入代理

从标签角度看，独立游戏也不能只依赖Indie这类宽泛标签。Indie覆盖游戏数量很大，但竞争也非常激烈。进一步观察买断制独立游戏中的标签可以发现，Kickstarter标签的估计拥有者中位数达到75000，中位评论数为878，说明拥有社区基础或众筹背景的游戏更容易在发行前积累关注。Moddable、Turn-Based、4X、Lovecraftian、Steampunk等标签的估计拥有者中位数也相对较高，说明具有明确玩法机制、题材风格或可扩展内容的游戏更容易形成可识别的市场定位。另一方面，Sokoban、Wholesome、Cozy、Cats等标签的估计拥有者中位数不算高，但好评率中位数超过90%，更接近“小市场、高口碑”的细分方向。这对小团队有一定启发：如果无法追求大规模曝光，选择明确的细分玩法或情绪体验，也可能获得较稳定的目标玩家反馈。

对于高投入发行商来说，销量规模之外，更需要关注讨论热度和持续参与。讨论热度较高的游戏中，既有Counter-Strike 2、PUBG:BATTLEGROUNDS、Dota 2这类免费或长线运营游戏，也有Rust、ELDEN RING、Stardew Valley、Terraria、Black

Myth:Wukong、Baldur's Gate 3等买断制游戏。这说明高讨论度既可能来自多人竞技和在线社区，也可能来自强内容体量、强口碑或高话题度。特别是Wallpaper Engine这种工具型产品也进入高讨论样本，说明Steam中的“高热度”并不只属于传统意义上的游戏。因此，对于大体量发行商而言，不能只看估计拥有者规模，还要同时关注评论数、推荐数、峰值在线人数和好评率，判断游戏是“卖得多”“讨论多”，还是“卖得多但争议也大”。

对于免费在线运营游戏，estimated_owners更接近入库或触达规模，不能直接理解为收入。这类游戏更应关注评论数量、好评率和峰值在线人数。在免费游戏标签中，Idler、Moddable、MMORPG、Online Co-Op、Co-op等标签表现较突出，说明轻量化持续游玩、可扩展内容和多人互动仍然是免费游戏比较重要的吸引点。例如Idler类游戏的中位评论数达到438.5，峰值在线人数中位数为11.5；MMORPG和Co-op标签的估计拥有者中位数达到350000，也说明免费游戏更依赖持续进入、持续游玩和社交传播，而不是一次性购买。

另外，一个比较值得注意的额外现象是，成人向或成熟内容相关标签在部分结果中表现明显。如图8所示，在免费游戏的反馈与参与度综合得分中，Hentai、Mature等标签进入了较靠前的位置。结合具体统计结果看，Hentai标签的中位评论数达到1189，好评率中位数约83.98%；Mature标签的中位评论数达到1071，好评率中位数约81.59%。这说明成人向内容确实是Steam生态中不可忽视的一个特殊细分市场，部分小型发行方可能会利用明确受众、低制作门槛和标签流量来获得销量或讨论度。但这一现象也反映出潜在问题：当某类标签能够以较低成本换取一定曝光时，平台中就容易出现低质量作品集中、题材同质化和标签滥用的情况。因此，这一发现不应被简单理解为发行建议，而更像是Steam市场结构中的一个特殊分支，说明平台生态并不只由传统游戏类型构成，也包含一些依赖强刺激标签和垂直受众的灰色增长空间。




图 8: 免费游戏标签的反馈与参与度综合得分

总体来看, Steam发行策略需要先区分目标: 买断制独立游戏更应关注价格区间、细分标签和估计销量代理; 高投入游戏需要同时追踪销量、讨论热度和口碑; 免费在线游戏则更依赖评论反馈、峰值在线和持续参与。数据分析不能直接告诉开发者“做什么一定成功”, 但可以帮助发行方避免只凭直觉选择题材、定价和标签。真正有价值的不是追逐最热门标签, 而是在目标玩家、商业模式和竞争强度之间找到更合适的位置。

9 不足与改进方向

9.1 当前不足

本次实践主要基于Kaggle整理的Steam Games Dataset 2025进行分析, 数据并非Steam官方直接发布, 因此在字段完整性、采集口径和更新频率上可能存在一定限制。尤其是estimated_owners这类字段只能作为估计销量规模的代理指标, 不能等同于真实销量。

其次, 本文分析以描述性统计和可视化观察为主, 重点在于发现市场结构、玩家反馈和标签定位中的现象, 而不是建立严格的因果模型。因此, 价格、平台支持、标签特征与玩家关注度之间的关系, 只能说明存在一定相关现象, 不能直接解释为某一因素导致了更高销量或更高热度。

此外, Steam标签本身也存在一定主观性。一款游戏的标签可能受到玩家标注、发行方设置和平台机制影响, 并不完全等同于游戏真实内容。对于成人向、独立游戏、休闲游戏等标签, 也可能存在标签过宽、标签滥用或内部差异较大的问题, 这会影响部分细分分析的准确性。

9.2 后续方向

后续可以在当前分析基础上进一步加入建模方法。例如, 可以使用PCA对价格、评论数、推荐数、峰值在线人数、好评率、标签数量等特征进行降维, 观察Steam游戏在综合特征空间中的分布情况; 也可以使用聚类方法, 将游戏划分为不同市场类型, 例如高热度头部游戏、小众高口碑游戏、低价长尾游戏和免费运营游戏等。

同时, 也可以进一步尝试构建简单的预测模型。比如以评论数、推荐数、峰值在线人数或estimated_owners作为目标变量, 分析哪些特征对玩家关注度或估计销量更有解释作用。不过这类模型仍需要注意数据口径问题, 不能简单将预测结果理解为真实商业结论。

另一个可扩展方向是相似游戏推荐。后续可以综合使用genres、categories、tags、文本描述和玩家反馈指标, 计算游戏之间的相似度, 并结合评论数量、好评率和热度

指标进行过滤或排序。这样可以把前面对标签、类型和市场定位的分析进一步转化为一个更具体的应用场景。

参考资料

- [1] Li, Xiping, et al. “Category-based and popularity-guided video game recommendation: a balance-oriented framework.” *Proceedings of the ACM Web Conference 2024*. 2024.
- [2] Li, Xiping, et al. “CPGRec+: A Balance-oriented Framework for Personalized Video Game Recommendations.” *ACM Transactions on Information Systems* 44.3 (2026): 1–44.
- [3] Grelier, Nicolas, and Stéphane Kaufmann. “A data-driven classification of video game vocabulary.” *International Conference on Entertainment Computing*. Singapore: Springer Nature Singapore, 2023.
- [4] Oktarian, Abit Ahmad, et al. “Enhancing Game Review Sentiment Classification on Steam Platform with Attention-Based BiLSTM.” *arXiv preprint arXiv:2605.01315* (2026).
- [5] De Luisa, Andraž, et al. “Predicting the popularity of games on steam.” *arXiv preprint arXiv:2110.02896* (2021).